

Métodos alternativos de clustering para la descomposición dinámica de galaxias en simulaciones astrofísicas

Nicolás Uriel Navall¹
Dr. Juan Cabral²
Dr. Pablo Granitto¹
Lic. Valeria Cristiani²

¹Universidad Nacional de Rosario
Facultad de Ciencias Exactas, Ingeniería y Agrimensura

²Universidad Nacional de Córdoba
Facultad de Matemática, Astronomía, Física y Computación

Noviembre 2024

2024-11-20

Métodos alternativos de clustering para la descomposición dinámica de galaxias en simulaciones astrofísicas

Nicolás Uriel Navall¹
Dr. Juan Cabral²
Dr. Pablo Granitto¹
Lic. Valeria Cristiani²

¹Universidad Nacional de Rosario
Facultad de Ciencias Exactas, Ingeniería y Agrimensura
²Universidad Nacional de Córdoba
Facultad de Matemática, Astronomía, Física y Computación

Noviembre 2024


Avanzar en la comprensión de las galaxias simuladas desde el punto de vista de sus componentes, utilizando un enfoque multidisciplinario que combine técnicas de machine learning y astronomía.

Avanzar en la comprensión de las galaxias simuladas desde el punto de vista de sus componentes, utilizando un enfoque multidisciplinario que combine técnicas de machine learning y astronomía.

Problema: Falta de etiquetas

Problema: Falta de etiquetas

Tipos de galaxias



- Galaxias elípticas
- Galaxias espirales

2024-11-20

Antecedentes

Tipos de galaxias




- Galaxias elípticas
- Galaxias espirales

- Clasificación morfológica o **secuencia de Hubble**
- galaxias elípticas (**E0-E7**)
- rama superior galaxias espirales sin barra
- rama inferior galaxias espirales con barra

Componentes de una galaxia


- Esferoide
 - Bulge
 - Halo
- Disco
 - Disco delgado
 - Disco grueso



2024-11-20

- └ Antecedentes
- └ Componentes de una galaxia







2024-11-20

Antecedentes

Problema observacional




- Problema en una proyección una estrella podría parecer que está en el esferoide mientras que **en realidad está en el disco**.
- El area ha enfocado sus **esfuerzos en las características dinámicas de estrellas** en las componentes
- Estas características (posiciones y velocidades de estrellas) no se pueden obtener con **telescopios actuales**, por lo cual **recurrimos a las simulaciones**



2024-11-20

Antecedentes

Simulaciones



- Estas simulaciones nos brindan la posibilidad de acceder a esta información.
- Estado del arte

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

- Parámetro de circularidad (*eps*):

$$\epsilon = \frac{J_z(E)}{J_{\text{circ}}(E)}$$

2024-11-20

Antecedentes

Parámetros

Parámetros

- Parámetro de circularidad (*eps*):

$$\epsilon = \frac{J_z(E)}{J_{\text{circ}}(E)}$$

- Así, los tres valores que representan los movimientos de una partícula estelar y definen su ubicación en alguna de las componentes son
- *eps*: Cuán **parecida** es la órbita de una partícula respecto a una **órbita circular**, para un dado valor de energía.

- Parámetro de circularidad (ϵ):

$$\epsilon = \frac{J_z(E)}{J_{\text{circ}}(E)}$$

- Parámetro de circularidad proyectada (ϵ_r):

$$\epsilon_r = \frac{J_p(E)}{J_{\text{circ}}(E)}$$

Donde $J_p = \sqrt{J_x^2 + J_y^2}$

2024-11-20

Antecedentes

Parámetros

Parámetros

- Parámetro de circularidad (ϵ):

$$\epsilon = \frac{J_z(E)}{J_{\text{circ}}(E)}$$

- Parámetro de circularidad proyectada (ϵ_r):

$$\epsilon_r = \frac{J_p(E)}{J_{\text{circ}}(E)}$$

Donde $J_p = \sqrt{J_x^2 + J_y^2}$

- Así, los tres valores que representan los movimientos de una partícula estelar y definen su ubicación en alguna de las componentes son
- ϵ : Cuán **parecida** es la órbita de una partícula respecto a una **órbita circular**, para un dado valor de energía.
- ϵ_r : Representa la **dispersión vertical** del movimiento de una partícula con respecto al **plano** en el que se ubican las **partículas** que se mueven en **órbitas circulares**.

- Parámetro de circularidad (eps):

$$\epsilon = \frac{J_z(E)}{J_{circ}(E)}$$

- Parámetro de circularidad proyectada (eps_r):

$$\epsilon_r = \frac{J_p(E)}{J_{circ}(E)}$$

Donde $J_p = \sqrt{J_x^2 + J_y^2}$

- Energía estelar normalizada ($normalized_star_energy$):

$$E/|E|_{max}$$

2024-11-20

Antecedentes

Parámetros

Parámetros

- Parámetro de circularidad (eps):

$$\epsilon = \frac{J_z(E)}{J_{circ}(E)}$$

- Parámetro de circularidad proyectada (eps_r):

$$\epsilon_r = \frac{J_p(E)}{J_{circ}(E)}$$

Donde $J_p = \sqrt{J_x^2 + J_y^2}$

- Energía estelar normalizada ($normalized_star_energy$):

$$E/|E|_{max}$$

- Así, los tres valores que representan los movimientos de una partícula estelar y definen su ubicación en alguna de las componentes son
- eps : Cuán **parecida** es la órbita de una partícula respecto a una **órbita circular**, para un dado valor de energía.
- eps_r : Representa la **dispersión vertical** del movimiento de una partícula con respecto al **plano** en el que se ubican las **partículas** que se mueven en **órbitas circulares**.
- $norm$: **que tan ligada** esta la partícula a la galaxia
- Las partículas más ligadas al sistema van a adoptar valores cercanos a -1, mientras que las menos ligadas van a tener valores cercanos a 0.

- Parámetro de circularidad (ϵ):

$$\epsilon = \frac{J_z(E)}{J_{\text{circ}}(E)}$$

- Parámetro de circularidad proyectada (ϵ_r):

$$\epsilon_r = \frac{J_p(E)}{J_{\text{circ}}(E)}$$

Donde $J_p = \sqrt{J_x^2 + J_y^2}$

- Energía estelar normalizada ($\text{normalized_star_energy}$):

$$E/|E|_{\text{max}}$$

2024-11-20

Antecedentes

Parámetros

Parámetros

- Parámetro de circularidad (ϵ):

$$\epsilon = \frac{J_z(E)}{J_{\text{circ}}(E)}$$
- Parámetro de circularidad proyectada (ϵ_r):

$$\epsilon_r = \frac{J_p(E)}{J_{\text{circ}}(E)}$$

Donde $J_p = \sqrt{J_x^2 + J_y^2}$

- Energía estelar normalizada ($\text{normalized_star_energy}$):

$$E/|E|_{\text{max}}$$

- Así, los tres valores que representan los movimientos de una partícula estelar y definen su ubicación en alguna de las componentes son
- ϵ : Cuán **parecida** es la órbita de una partícula respecto a una **órbita circular**, para un dado valor de energía.
- ϵ_r : Representa la **dispersión vertical** del movimiento de una partícula con respecto al **plano** en el que se ubican las **partículas** que se mueven en **órbitas circulares**.
- norm : **que tan ligada** esta la partícula a la galaxia
- Las partículas más ligadas al sistema van a adoptar valores cercanos a -1, mientras que las menos ligadas van a tener valores cercanos a 0.

- Abadi
- Auto-Gaussian Mixture Model (AGMM)



<https://github.com/vcristiani/galaxy-chop>



2024-11-20

Antecedentes

Métodos Establecidos

Métodos Establecidos

- Abadi
- Auto-Gaussian Mixture Model (AGMM)



<https://github.com/vcristiani/galaxy-chop>

- Abadi: Usa **eps** para separar en **Disco** y **Esferoide**. Asume que la componente esferoidal no presenta rotación y por lo tanto está representada por una distribución simétrica respecto de $\epsilon = 0$. Para ello selecciona el mismo número de partículas en órbitas corrotantes que aquellas que se encuentran en órbitas contrarrotantes. Luego, la distribución de las partículas restantes, se asignará al disco. Esto se debe a que el método asume que el disco está formado por partículas cuyo movimiento predominante es el de rotación. Como reflejo de esto, las partículas asignadas al disco tendrán $\epsilon \sim 1$.

- AGMM: Realiza **distribuciones Gaussianas** que representan las estructuras a ser identificadas, utilizando *eps*, *eps_r* y *normalized_star_energy*. Genera dichos modelos variando el **número de componentes a buscar de 2 a 9**. En cada iteración, se crean 10 modelos con diferentes inicializaciones para alcanzar resultados más estables. El algoritmo usa una función a minimizar y un valor de disparo previamente establecido. Como la iteración comienza con 2 grupos y crece desde ahí, se tiene preferencia en buscar

Metodos de Clustering

2024-11-20

└─Antecedentes

└─Metodos de Clustering

- Utilizaremos entonces metodos de Clustering (que son no-supervisados) para asignar las partículas estelares a las diferentes componentes galácticas. Los algoritmos de *clustering* tienen la **tarea de agrupar un conjunto de objetos** de tal manera que los objetos de un mismo grupo (llamado *cluster*) sean **más similares**, en algún sentido, entre sí **que los de otros** grupos (*clusters*).

- Métodos jerárquicos

2024-11-20

└─ Antecedentes

└─ Metodos de Clustering

• Métodos jerárquicos

- Jerarquico: Crean agrupamientos basándose en agrupamientos más pequeños de una manera jerárquica. Buscamos reflejar **estructura jerarquica de galaxia**.

Antecedentes

└ Metodos de Clustering

- Métodos jerárquicos
- Métodos difusos/*fuzzy*

- Jerárquico: Crean agrupamientos basándose en agrupamientos más pequeños de una manera jerárquica. Buscamos reflejar **estructura jerárquica de galaxia**.
- Fuzzy: Dado que una partícula de varias masas solares **puede pertenecer a más de una componente** galáctica al mismo tiempo, queremos evaluar cómo se comporta los métodos de agrupamientos basados en **lógica difusa** para la asignación de la misma partícula en diferentes componentes.


- Métodos jerárquicos
- Métodos difusos/*fuzzy*
- Métodos basados en acumulación de evidencia

- Jerarquico: Crean agrupamientos basándose en agrupamientos más pequeños de una manera jerárquica. Buscamos reflejar **estructura jerarquica de galaxia**.
- Fuzzy: Dado que una partícula de varias masas solares **puede pertenecer a más de una componente** galáctica al mismo tiempo, queremos evaluar cómo se comporta los métodos de agrupamientos basados en **lógica difusa** para la asignación de la misma partícula en diferentes componentes.
- EAC: Permiten **combinar y consensuar** resultados provenientes de

- Métodos jerárquicos
- Métodos difusos/*fuzzy*
- Métodos basados en acumulación de evidencia

- Jerarquico: Crean agrupamientos basándose en agrupamientos más pequeños de una manera jerárquica. Buscamos reflejar **estructura jerarquica de galaxia**.
- Fuzzy: Dado que una partícula de varias masas solares **puede pertenecer a más de una componente** galáctica al mismo tiempo, queremos evaluar cómo se comporta los métodos de agrupamientos basados en **lógica difusa** para la asignación de la misma partícula en diferentes componentes.
- EAC: Permiten **combinar y consensuar** resultados provenientes de

Métricas de validación externa



How many retrieved items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant items are retrieved?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

2024-11-20

Antecedentes

Métricas de validación externa



- Clustering **discierne grupos entre sí**, no los cataloga. Una vez **etiquetados los datos manualmente**, es necesario **compararlos** con los obtenidos con algún método que tengan una fundamentación física sólida y además provean estas etiquetas. Los resultados de estos metodos los llamaremos GT, y vendran de **Abadi** y **AGMM**. Teniendo el cuidado de utilizar los mismos parámetros dinámicos en cada caso.
- Presicion: Cuánto de lo que seleccioné era realmente relevante.
- Recall: Cuánto de lo relevante fue seleccionado.

Antecedentes

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

- $a(i)$: promedio de la distancia entre el punto i con todos los puntos del mismo cluster
- $b(i)$: promedio de la distancia entre el punto i con todos los puntos del cluster más cercano

- └ Métricas de validación interna

- Utilizan todo el conjunto de datos que se usó para entrenar al modelo, y analizan la **distancia intra y extra cluster**, y la continuidad espacial que tienen los datos dentro de sus clusters. Esto da una idea de la estructura interna sin necesidad de recurrir a valores externos.
- Silhouette: El puntaje es el promedio del coeficiente en cada punto. Valores ~ 1 *clusters* están bien separados entre si y son a su vez bien compactos; valores ~ -1 existen puntos mal clasificados; ~ 0 existe una superposición entre *clusters*
- Davies Bouldin: Valores ~ 0 mejor agrupamiento, valores alejados de 0 (hasta infinito) dan a entender un mal trabajo de *clustering*.
- Valores **alejados del ideal** no esta necesariamente mal, depende de la **naturaleza de los clusters**

- Puntaje de Silhouette (SSc)

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

- $a(i)$: promedio de la distancia entre el punto i con todos los puntos del mismo cluster
- $b(i)$: promedio de la distancia entre el punto i con todos los puntos del cluster más cercano

- Índice de Davies–Bouldin (DBI)

Busca para todos los *clusters* c_i , el *cluster* c_j que maximiza el valor R_{ij} , para luego promediar todos los valores R_{ij} obtenidos.

- s_i : La distancia promedio de cada punto en el *cluster* c_i al centro de su mismo *cluster*
- d_{ij} : Distancia entre los centros de los *clusters* c_i y c_j
- R_{ij} : La suma de s_i y s_j dividido d_{ij}

2024-11-20

Antecedentes

Métricas de validación interna

Métricas de validación interna

● Puntaje de Silhouette (SSc)

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

- $a(i)$: promedio de la distancia entre el punto i con todos los puntos del mismo cluster
- $b(i)$: promedio de la distancia entre el punto i con todos los puntos del cluster más cercano

● Índice de Davies–Bouldin (DBI)


Busca para todos los *clusters* c_i , el *cluster* c_j que maximiza el valor R_{ij} , para luego promediar todos los valores R_{ij} obtenidos.

- s_i : La distancia promedio de cada punto en el *cluster* c_i al centro de su mismo cluster
- d_{ij} : Distancia entre los centros de los *clusters* c_i y c_j
- R_{ij} : La suma de s_i y s_j dividido d_{ij}

- Utilizan todo el conjunto de datos que se usó para entrenar al modelo, y analizan la **distancia intra y extra cluster**, y la continuidad espacial que tienen los datos dentro de sus clusters. Esto da una idea de la estructura interna sin necesidad de recurrir a valores externos.
- Silhouette: El puntaje es el promedio del coeficiente en cada punto. Valores ~ 1 *clusters* están bien separados entre si y son a su vez bien compactos; valores ~ -1 existen puntos mal clasificados; ~ 0 existe una superposición entre *clusters*
- Davies Bouldin: Valores ~ 0 mejor agrupamiento, valores alejados de 0 (hasta infinito) dan a entender un mal trabajo de *clustering*.
- Valores **alejados del ideal** no esta necesariamente mal, depende de la **naturaleza de los clusters**

Análisis físicos del área

Curva de Perfil de Velocidades




2024-11-20

Antecedentes

Análisis físicos del área

Análisis físicos del área




- Muestran la **velocidad de rotación** de las componentes en una galaxia en función de su **distancia radial al centro** de las mismas.
- Si **superponemos nuestras curvas** con GT, ver si en la dinámica de las componentes identificadas se reproducen los comportamientos típicos estudiados en la física; esto lo vuelve una **métrica externa**.

2024-11-20



└─Antecedentes

└─Remover Atípicos/Outliers


- Podemos considerar atípicos a valores que están muy **alejados del centro galáctico** y puede que estén muy **débilmente ligados gravitacionalmente**




- Isolation Forest



- Podemos considerar atípicos a valores que están muy **alejados del centro galáctico** y puede que estén muy **débilmente ligados gravitacionalmente**
- IF: Detecta anomalías mediante árboles binarios. Divide el espacio de datos mediante **líneas paralelas a la base canónica** y asigna puntuaciones de anomalía a los datos, con valores más altos a los puntos de datos que necesitan menos divisiones para ser aislados.




• Isolation Forest





• R-Cut

- Podemos considerar atípicos a valores que están muy **alejados del centro galáctico** y puede que estén muy **débilmente ligados gravitacionalmente**
- IF: Detecta anomalías mediante árboles binarios. Divide el espacio de datos mediante **líneas paralelas a la base canónica** y asigna puntuaciones de anomalía a los datos, con valores más altos a los puntos de datos que necesitan menos divisiones para ser aislados.
- R-Cut: Desde el punto de vista de la astrofísica, es habitual considerar a las galaxias como las partículas estelares con radio $r \leq XKpc$, donde X es 3 veces el radio que encierra la mitad de la masa estelar. Esta heurística es usada en diversos trabajos como una **forma rápida de descartar valores** que es poco probable que pertenezcan a la galaxia, pero que el algoritmo que identifica las galaxias las haya asignado allí.



Isolation Forest



RCut

- Podemos considerar atípicos a valores que están muy **alejados del centro galáctico** y puede que estén muy **débilmente ligados gravitacionalmente**
- IF: Detecta anomalías mediante árboles binarios. Divide el espacio de datos mediante **líneas paralelas a la base canónica** y asigna puntuaciones de anomalía a los datos, con valores más altos a los puntos de datos que necesitan menos divisiones para ser aislados.
- RCut: Desde el punto de vista de la astrofísica, es habitual considerar a las galaxias como las partículas estelares con radio $r \leq XKpc$, donde X es 3 veces el radio que encierra la mitad de la masa estelar. Esta heurística es usada en diversos trabajos como una **forma rápida de descartar valores** que es poco probable que pertenezcan a la galaxia, pero que el algoritmo que identifica las galaxias las haya asignado allí.

Recursos computacionales proveídos por:



Universidad
Nacional
de Córdoba

I A T E



Centro de
Computación
de Alto
Desempeño



2024-11-20

Antecedentes

Recursos computacionales

- Algoritmos son **caros computacionalmente y en memoria** con la gran cantidad de datos que analizamos, por lo cual requerimos de supercomputadoras para correrlos.
- **Instituto de Astronomía Teórica y Experimental**, y el **Centro de computacion de alto desempeño** de la Universidad Nacional de Córdoba
- **Centro Extremeño de Investigación, Innovación Tecnológica y Supercomputación**, que forman parte de la Fundación Computación y Tecnologías Avanzadas de Extremadura de la **Red Española de Supercomputación**.



Clustering Jerárquico

2024-11-20

└ Clustering Jerárquico

└ Clustering Jerárquico



- Familia de algoritmos que buscan en los datos **grupos organizados jerárquicamente**. Así, a medida que se aumenten la cantidad de clusters buscados, estos se irán dividiendo o fusionando hasta alcanzar el número deseado

Clustering Jerárquico

2024-11-20

Clustering Jerárquico

Clustering Jerárquico





- Familia de algoritmos que buscan en los datos **grupos organizados jerárquicamente**. Así, a medida que se aumenten la cantidad de clusters buscados, estos se irán dividiendo o fusionando hasta alcanzar el número deseado
- Cada observación comienza en su propio grupo, y los pares de grupos son mezclados mientras uno sube en la jerarquía.
- Para poder decidir qué grupos deberían ser combinados o cuando un grupo debería ser dividido se requiere una **medida de disimilitud** entre conjuntos de observaciones. Esta medida es llamada **linkage**, y la librería utilizada tiene las siguientes disponibles:

Clustering Jerárquico

2024-11-20

Clustering Jerárquico

Clustering Jerárquico



- Familia de algoritmos que buscan en los datos **grupos organizados jerárquicamente**. Así, a medida que se aumenten la cantidad de clusters buscados, estos se irán dividiendo o fusionando hasta alcanzar el número deseado
- Cada observación comienza en su propio grupo, y los pares de grupos son mezclados mientras uno sube en la jerarquía.
- Para poder decidir qué grupos deberían ser combinados o cuando un grupo debería ser dividido se requiere una **medida de disimilitud** entre conjuntos de observaciones. Esta medida es llamada **linkage**, y la librería utilizada tiene las siguientes disponibles:

- Ward

2024-11-20

└ Clustering Jerárquico

└ Tipos de linkage

• Ward

- Ward: Minimiza la **suma de las diferencias al cuadrado dentro** de todos los clusters. Es un enfoque de **minimización de la varianza**.

- Clustering Jerárquico

- └Tipos de linkage

- Ward
- Complete

- Ward: Minimiza la **suma de las diferencias al cuadrado** dentro de todos los clusters. Es un enfoque de **minimización de la varianza**.
- Complete: Minimiza la **distancia máxima entre observaciones** de pares de clusters.

- Ward
- Complete
- Average

2024-11-20

└ Clustering Jerárquico

└ Tipos de linkage

• Ward
• Complete
• Average

- Ward: Minimiza la **suma de las diferencias al cuadrado dentro** de todos los clusters. Es un enfoque de **minimización de la varianza**.
- Complete: Minimiza la **distancia máxima entre observaciones** de pares de clusters.
- Average: Minimiza la **media de las distancias** entre todas las observaciones de pares de conglomerados.

- Ward
- Complete
- Average
- Single

- Ward: Minimiza la **suma de las diferencias al cuadrado dentro** de todos los clusters. Es un enfoque de **minimización de la varianza**.
- Complete: Minimiza la **distancia máxima entre observaciones** de pares de clusters.
- Average: Minimiza la **media de las distancias** entre todas las observaciones de pares de conglomerados.
- Single: Minimiza la distancia entre las observaciones **más cercanas de pares** de conglomerados.

2024-11-20

- Tipos de linkage

- Ward
- Complete
- Average
- Single

- Ward: Minimiza la **suma de las diferencias al cuadrado** dentro de todos los clusters. Es un enfoque de **minimización de la varianza**.
- Complete: Minimiza la **distancia máxima entre observaciones** de pares de clusters.
- Average: Minimiza la **media de las distancias** entre todas las observaciones de pares de conglomerados.
- Single: Minimiza la distancia entre las observaciones **más cercanas de pares** de conglomerados.
- Usamos **aglomerativo** ya que parece ser el que mejores resultados da en el área de estudio
- Para **decidir sobre el linkage** a utilizar realizamos los experimentos descritos a continuación

└ Clustering Jerárquico

- Tipos de linkage

- Ward
- Complete
- Average
- Single

- Ward: Minimiza la **suma de las diferencias al cuadrado dentro** de todos los clusters. Es un enfoque de **minimización de la varianza**.
- Complete: Minimiza la **distancia máxima entre observaciones** de pares de clusters.
- Average: Minimiza la **media de las distancias** entre todas las observaciones de pares de conglomerados.
- Single: Minimiza la distancia entre las observaciones **más cercanas de pares** de conglomerados.
- Usamos **aglomerativo** ya que parece ser el que mejores resultados da en el área de estudio
- Para **decidir sobre el linkage** a utilizar realizamos los experimentos descritos a continuación



<https://scikit-learn.org/stable/>

2024-11-20


└ Clustering Jerárquico

└ Librería utilizada

Librería utilizada




<https://scikit-learn.org/stable/>





2024-11-20

- └ Clustering Jerárquico
 - └ Selección de linkage

- Aplicamos todos los linkages y comparamos con el método de Abadi, sobre un conjunto de 9 galaxias.








2024-11-20

Clustering Jerárquico



Abadi: Detección de 2 componentes

- recordamos que se usan las **mismas features que Abadi**, buscando 2 clusters
- **corte en vertical** feo por falta de heurística, es el **mejor resultado** al cual se puede aspirar
- Esta situación hace que haya una **sobreestimación del esferoide** como se ve en los perfiles de velocidad





- **no podemos concluir** que ayuda ni que no, para rcut ni para isolation forest




- aunque en líneas generales parece dar **bien** le falta la sutileza de la **interpretacion fisica** que le da abadi a los valores
- cj es **mas caro computacionalmente** que abadi ($O(n^2)$), incluso si da mejor no nos sirve como alternativa del dia a dia

2024-11-20


└ Clustering Jerárquico

└ AGMM: Detección de $\Rightarrow 2$ componentes





AutoGMM

Ward



- **Halo y Bulge se ven separados en eps en lugar de solapados**
- Como el linkage **Ward** busca **minimizar la varianza de cada cluster**, esto se traduce en buscar que los **clusters estén lo más separados entre ellos**, lo cual va en directa contraposición con la **naturaleza de las componentes mencionadas** (incluso si esta bien para clusterización en general)


AGMM: Detección de $\Rightarrow 2$ componentes



2024-11-20

Clustering Jerárquico

AGMM: Detección de $\Rightarrow 2$ componentes




- Las metricas internas dicen que ward da mejor que agmm, pero **esta mal**
- Distinción entre lo que es **más correcto** a la hora de **buscar clusters abstractos** contra buscar componentes de una galaxia
- Estas métricas son calculadas a partir del **concepto ideal abstracto de cluster**, el cual se basa en que éstos sean compactos, separados espacialmente están entre ellos, y que exista “continuidad” en cada uno.

Base

RCut

Isolation Forest





2024-11-20

Clustering Jerárquico

AGMM: Eliminación de outliers

- remover outliers te puede cambiar la **cantidad de clusters** encontrados por como funciona agmm, lo cual dificulta la comparacion






2024-11-20

└ Clustering Jerárquico

└ AGMM: Eliminación de outliers



- en el apendice tenemos mas ejemplos, pero dadas las galaxias cuya cardinalidad de componentes no vario al remover analisis (menos de la mitad de nuestro adataset), **no podemos concluir** tampoco si hacerlo nos da mejores o peores resultados.

Fuzzy Clustering

2024-11-20

└ Fuzzy Clustering

└ Fuzzy Clustering

Es un método de clustering en el cual cada punto de los datos puede **pertenecer a más de un cluster**, mediante la asignación de valores de pertenencia a cada punto de nuestros datos por cada cluster que estemos buscando. Así, puntos cerca del borde de un cluster obtienen un bajo valor de pertenencia.

Dado $X = (x_1, x_2, \dots, x_k)$, con k puntos de datos y c clusters.

Es un método de clustering en el cual cada punto de los datos puede **pertenecer a más de un cluster**, mediante la asignación de valores de pertenencia a cada punto de nuestros datos por cada cluster que estemos buscando. Así, puntos cerca del borde de un cluster obtienen un bajo valor de pertenencia.

Dado $X = (x_1, x_2, \dots, x_k)$, con k puntos de datos y c clusters.
Definimos la función de pertenencia como:

$$\mu_{ij} = \mu_i(x_j) \in [0, 1] \quad \forall i = 1, \dots, c \wedge \forall j = 1, \dots, k \quad (1)$$

Es un método de clustering en el cual cada punto de los datos puede **pertenecer a más de un cluster**, mediante la asignación de valores de pertenencia a cada punto de nuestros datos por cada cluster que estemos buscando. Así, puntos cerca del borde de un cluster obtienen un bajo valor de pertenencia.

Dado $X = (x_1, x_2, \dots, x_k)$, con k puntos de datos y c clusters.

Definimos la función de pertenencia como:

$$\mu_{ij} = \mu_i(x_j) \in [0, 1] \quad \forall i = 1, \dots, c \wedge \forall j = 1, \dots, k \quad (1)$$

De forma tal que:

$$\sum_{i=1}^c \mu_i(x_j) = 1 \quad \forall j = 1, \dots, k \quad (2)$$

Dado $X = (x_1, x_2, \dots, x_k)$, con k puntos de datos y c clusters.
Definimos la función de pertenencia como:

$$\mu_{ij} = \mu_i(x_j) \in [0, 1] \quad \forall i = 1, \dots, c \wedge \forall j = 1, \dots, k \quad (1)$$

De forma tal que:

$$\sum_{i=1}^c \mu_i(x_j) = 1 \quad \forall j = 1, \dots, k \quad (2)$$

Es un método de clustering en el cual cada punto de los datos puede **pertenecer a más de un cluster**, mediante la asignación de valores de pertenencia a cada punto de nuestros datos por cada cluster que estemos buscando. Así, puntos cerca del borde de un cluster obtienen un bajo valor de pertenencia.

Luego, definimos el conjunto de particiones difusas de la siguiente manera:

$$M_{fc} = \{U \in \mathbb{R}^{c \times k} \mid U = [u_{ij}]; u_{ij} \in [0, 1] \forall i, j; \sum_{i=1}^c u_{ij} = 1 \forall j; \sum_{j=1}^k u_{ij} > 0 \forall i\} \quad (3)$$

2024-11-20

└ Fuzzy Clustering

└ Fuzzy Clustering

- Que representa una particion difusa (sus elementos)

$$M_{fc} = \{U \in \mathbb{R}^{c \times k} \mid U = [u_{ij}]; u_{ij} \in [0, 1] \forall i, j; \sum_{i=1}^c u_{ij} = 1 \forall j; \sum_{j=1}^k u_{ij} > 0 \forall i\} \quad (3)$$

Luego, definimos el conjunto de particiones difusas de la siguiente manera:

$$M_{fc} = \{U \in \mathbb{R}^{c \times k} \mid U = [u_{ij}]; u_{ij} \in [0, 1] \forall i, j; \sum_{i=1}^c u_{ij} = 1 \forall j; \sum_{j=1}^k u_{ij} > 0 \forall i\} \quad (3)$$

Función de error mínimo cuadrático:

$$J_m(U, v) = \sum_{j=1}^k \sum_{i=1}^c (u_{ij})^m d_{ij}^2 \quad (4)$$

- d_{ij} : Distancia Euclidiana entre el elemento x_j y el centro del cluster i
- $U \in M_{fc}$: Contiene todos los pesos u_{ij} asociados a las distancias cuadradas
- v : El vector centro de cada cluster
- m : Valor de fuzziness

2024-11-20

└ Fuzzy Clustering

└ Fuzzy Clustering

- Que representa una particion difusa (sus elementos)
- Podemos **traducir el problema** de FCM a buscar una particion difusa (es decir, una matriz perteneciente al conjunto descrito arriba) **"optima"**

$$M_{fc} = \{U \in \mathbb{R}^{c \times k} \mid U = [u_{ij}], u_{ij} \in [0, 1] \forall i, j; \sum_{i=1}^c u_{ij} = 1 \forall j; \sum_{j=1}^k u_{ij} > 0 \forall i\} \quad (3)$$

Función de error mínimo cuadrático:

$$J_m(U, v) = \sum_{j=1}^k \sum_{i=1}^c (u_{ij})^m d_{ij}^2 \quad (4)$$

- d_{ij} : Distancia Euclidiana entre el elemento x_j y el centro del cluster i
- $U \in M_{fc}$: Contiene todos los pesos u_{ij} asociados a las distancias cuadradas
- v : El vector centro de cada cluster
- m : Valor de fuzziness

Luego, definimos el conjunto de particiones difusas de la siguiente manera:

$$M_{fc} = \{U \in \mathbb{R}^{c \times k} \mid U = [u_{ij}]; u_{ij} \in [0, 1] \forall i, j; \sum_{i=1}^c u_{ij} = 1 \forall j; \sum_{j=1}^k u_{ij} > 0 \forall i\} \quad (3)$$

Función de error mínimo cuadrático:

$$J_m(U, v) = \sum_{j=1}^k \sum_{i=1}^c (u_{ij})^m d_{ij}^2 \quad (4)$$

- d_{ij} : Distancia Euclidiana entre el elemento x_j y el centro del cluster i
- $U \in M_{fc}$: Contiene todos los pesos u_{ij} asociados a las distancias cuadradas
- v : El vector centro de cada cluster
- m : Valor de fuzziness

2024-11-20

└ Fuzzy Clustering

└ Fuzzy Clustering

- Que representa una particion difusa (sus elementos)

$$M_{fc} = \{U \in \mathbb{R}^{c \times k} \mid U = [u_{ij}], u_{ij} \in [0, 1] \forall i, j; \sum_{i=1}^c u_{ij} = 1 \forall j; \sum_{j=1}^k u_{ij} > 0 \forall i\} \quad (3)$$

Función de error mínimo cuadrático:

$$J_m(U, v) = \sum_{j=1}^k \sum_{i=1}^c (u_{ij})^m d_{ij}^2 \quad (4)$$

- d_{ij} : Distancia Euclidiana entre el elemento x_j y el centro del cluster i
- $U \in M_{fc}$: Contiene todos los pesos u_{ij} asociados a las distancias cuadradas
- v : El vector centro de cada cluster
- m : Valor de fuzziness

Algoritmo:

- 1 Fijar c , k y m . Elegir una matriz inicial $U^{(0)} \in M_{fc}$

2024-11-20

└ Fuzzy Clustering

└ Fuzzy Clustering

Algoritmo:
1 Fijar c , k y m . Elegir una matriz inicial $U^{(0)} \in M_{fc}$

- $m \rightarrow 1 = kmeans$, $m \rightarrow \infty =$ el mismo valor de pertenencia para todos los clusters
- Una vez terminado de correr el algoritmo, **etiquetamos** cada dato de nuestro conjunto con el cluster cuyo valor en la **partición difusa sea mayor**.

Algoritmo:

- 1 Fijar c , k y m . Elegir una matriz inicial $U^{(0)} \in M_{fc}$
- 2 Calcular los centros de los clusters como $v_i = \frac{\sum_{j=1}^k (u_{ij})^m x_j}{\sum_{j=1}^k (u_{ij})^m}; 1 \leq i \leq c$

2024-11-20

└ Fuzzy Clustering

└ Fuzzy Clustering

Fuzzy Clustering

Algoritmo:

- 1 Fijar c , k y m . Elegir una matriz inicial $U^{(0)} \in M_{fc}$
- 2 Calcular los centros de los clusters como $v_i = \frac{\sum_{j=1}^k (u_{ij})^m x_j}{\sum_{j=1}^k (u_{ij})^m}; 1 \leq i \leq c$

- $m \rightarrow 1 = kmeans$, $m \rightarrow \infty =$ el mismo valor de pertenencia para todos los clusters
- Una vez terminado de correr el algoritmo, **etiquetamos** cada dato de nuestro conjunto con el cluster cuyo valor en la **partición difusa** sea **mayor**.

Algoritmo:

- 1 Fijar c , k y m . Elegir una matriz inicial $U^{(0)} \in M_{fc}$
- 2 Calcular los centros de los clusters como $v_i = \frac{\sum_{j=1}^k (u_{ij})^m x_j}{\sum_{j=1}^k (u_{ij})^m}; 1 \leq i \leq c$
- 3 Actualizar la matriz de partición difusa $U = [u_{ij}]$ con

$$u_{ij} = \left(\sum_{n=1}^c \left(\frac{d_{ij}}{d_{nj}} \right)^{\frac{2}{m-1}} \right)^{-1}; 1 \leq j \leq k; 1 \leq i \leq c$$

2024-11-20

└ Fuzzy Clustering

└ Fuzzy Clustering

Algoritmo:
 1 Fijar c , k y m . Elegir una matriz inicial $U^{(0)} \in M_{fc}$
 2 Calcular los centros de los clusters como $v_i = \frac{\sum_{j=1}^k (u_{ij})^m x_j}{\sum_{j=1}^k (u_{ij})^m}; 1 \leq i \leq c$
 3 Actualizar la matriz de partición difusa $U = [u_{ij}]$ con
 $u_{ij} = \left(\sum_{n=1}^c \left(\frac{d_{ij}}{d_{nj}} \right)^{\frac{2}{m-1}} \right)^{-1}; 1 \leq j \leq k; 1 \leq i \leq c$

- $m \rightarrow 1 = kmeans$, $m \rightarrow \infty =$ el mismo valor de pertenencia para todos los clusters
- Una vez terminado de correr el algoritmo, **etiquetamos** cada dato de nuestro conjunto con el cluster cuyo valor en la **partición difusa sea mayor**.

Algoritmo:

- 1 Fijar c , k y m . Elegir una matriz inicial $U^{(0)} \in M_{fc}$
- 2 Calcular los centros de los clusters como $v_i = \frac{\sum_{j=1}^k (u_{ij})^m x_j}{\sum_{j=1}^k (u_{ij})^m}; 1 \leq i \leq c$
- 3 Actualizar la matriz de partición difusa $U = [u_{ij}]$ con

$$u_{ij} = \left(\sum_{n=1}^c \left(\frac{d_{ij}}{d_{nj}} \right)^{\frac{2}{m-1}} \right)^{-1}; 1 \leq j \leq k; 1 \leq i \leq c$$
- 4 Si se alcanza la máxima cantidad de iteraciones, o la diferencia de la matriz U con respecto a la iteración anterior es menor al error mínimo dado, el algoritmo termina. Caso contrario, vuelve al paso 2.

2024-11-20

Fuzzy Clustering

Fuzzy Clustering

- $m \rightarrow 1 = kmeans$, $m \rightarrow \infty =$ el mismo valor de pertenencia para todos los clusters
- Una vez terminado de correr el algoritmo, **etiquetamos** cada dato de nuestro conjunto con el cluster cuyo valor en la **partición difusa** sea **mayor**.

Algoritmo:

- 1 Fijar c , k y m . Elegir una matriz inicial $U^{(0)} \in M_{fc}$
- 2 Calcular los centros de los clusters como $v_i = \frac{\sum_{j=1}^k (u_{ij})^m x_j}{\sum_{j=1}^k (u_{ij})^m}; 1 \leq i \leq c$
- 3 Actualizar la matriz de partición difusa $U = [u_{ij}]$ con

$$u_{ij} = \left(\sum_{n=1}^c \left(\frac{d_{ij}}{d_{nj}} \right)^{\frac{2}{m-1}} \right)^{-1}; 1 \leq j \leq k; 1 \leq i \leq c$$
- 4 Si se alcanza la máxima cantidad de iteraciones, o la diferencia de la matriz U con respecto a la iteración anterior es menor al error mínimo dado, el algoritmo termina. Caso contrario, vuelve al paso 2.



<https://pythonhosted.org/scikit-fuzzy/>

2024-11-20


└ Fuzzy Clustering

└ Librería utilizada

Librería utilizada




<https://pythonhosted.org/scikit-fuzzy/>



Fuzziness	Centro de Esferoide
1.4	-0.078
14	0.008
140	0.027

2024-11-20

- Fuzzy Clustering
- Abadi: Búsqueda de m




Aumentar m movia la **línea de corte** hacia la **derecha**.

Abadi: Detección de 2 componentes

Concluimos en usar:

- 1 $m = 1.4$
- 2 Error mínimo = 0.00005
- 3 Iteraciones máximas = 1000




2024-11-20


Fuzzy Clustering

Abadi: Detección de 2 componentes

- Dado el dominio de resultados posibles, pasamos a elegir un **valor de fuzziness que acerque la linea de corte** al punto promedio en donde la densidad del Disco supera a la del Esferoide en todas las galaxias de nuestro dataset
- **Similar con CJ**, fuzzy es bueno al buscar 2 clusters entendiendo sus limitaciones?




Abadi: Eliminación de outliers



2024-11-20

└ Fuzzy Clustering


└ Abadi: Eliminación de outliers



- Aplicar IF y RCUT **apenas si modifican** los conjuntos encontrados de forma perceptible
- Esto se debe a que Fuzzy clustering es un método robusto dado que **limita el impacto de los outliers** al calcular los centros de los clusters, por lo que sacarlos apenas tiene efecto

AGMM: Detección de ≥ 2 componentes

- 1 $m = 3$
- 2 Error mínimo = 0.00005
- 3 Iteraciones máximas = 1000




2024-11-20


Fuzzy Clustering

AGMM: Detección de ≥ 2 componentes

- **busqueda de m** ahora tiene el **efecto esperado** al usar mas features
- Similar a CJ, los resultados son bastante **unidimensionales**
- Creemos que fue por una **sobre reelevancia de features**. Aunque eps nos sirva para identificar ambos discos, necesitamos utilizar mejor **normalized_star_energy** para identificar el **bulge** y el **halo**, como se puede ver en el siguiente histograma (otra diapo)



AGMM: Detección de ≥ 2 componentes





2024-11-20

└ Fuzzy Clustering

└ AGMM: Detección de ≥ 2 componentes

- Volvemos al **tercer paso del algo**, deriva el **valor de pertenencia** de cada partícula con cada cluster a partir de la **distancia** de ésta hacia el **centro de cada cluster**.






2024-11-20



└ Fuzzy Clustering

└ AGMM: Detección de ≥ 2 componentes

galaxy_TNG_389511 - AutoGMM




- Los valores de *eps* tienen un rango $[-1, 1]$, mientras que el rango de los valores de *normalized_star_energy* es $[-1, 0]$ y el de *eps_r* $[0, 1.5]$ (aunque a fines prácticos suele ser $[0, 1]$, incluso menor como se ve aca).
- Esto implica que haya **altas probabilidades** de que la **distancia** entre un punto a un cluster (y por consiguiente su **valor de pertenencia**) resulte fuertemente **dominado por eps**.




2024-11-20

Fuzzy Clustering

AGMM: Eliminación de outliers




- al igual que en la seccion anterior, tampoco obtuvimos diferencias tangibles al remover outliers dada la **robustez del metodo**
- **No es una buena alternativa de agmm**



2024-11-20

└ Evidence Accumulation Clustering

└ Evidence Accumulation Clustering



- Los métodos de clustering ensambles se basan en tomar **resultados** generados por **múltiples algoritmos** de clustering y llegar a un **consenso** que sea más correcto que los resultados individuales de los algoritmos utilizados.
- La idea detrás de EAC es entonces **combinar los resultados de múltiples** clusterings en una **única partición de datos**, interpretando cada uno de estos resultados como una “**evidencia independiente**” de la organización de los datos, como puede apreciarse en la figura

2024-11-20

- ## └ Evidence Accumulation Clustering

- Sea $X = x_1, x_2, \dots, x_n$ nuestro conjunto de datos donde $x_i \in \mathbb{R}^d$ y $\mathbb{R}^d$ es un espacio de d features.

- A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

2024-11-20

- ## └ Evidence Accumulation Clustering

- └ Evidence Accumulation Clustering

- donde C_j^i es el cluster j th en la partición P^i , la cual tiene k_i clusters.
- Además, dado n_j^i como la cardinalidad de C_j^i , se cumple que $\sum_{j=1}^{k_i} n_j^i = n$, $i = 1, \dots, N$.
- Cabe aclarar que los k pueden ser diferentes. EAC no asume el número de clusters k_i para cada partición obtenida P^i , por lo que cada k_i pueden ser no sólo diferentes al número de clusters buscado por EAC, sino que también entre sí.

- Sea $X = x_1, x_2, \dots, x_n$ nuestro conjunto de datos donde $x_i \in R^d$ y R^d es un espacio de d features.
- Partición P que encuentra k clusters
- Dado N algoritmos de clustering podemos entonces derivar N particiones P

2024-11-20

└ Evidence Accumulation Clustering

└ Evidence Accumulation Clustering

- donde C_j^i es el cluster j th en la partición P^i , la cual tiene k_i clusters.
- Además, dado n_j^i como la cardinalidad de C_j^i , se cumple que $\sum_{j=1}^{k_i} n_j^i = n$, $i = 1, \dots, N$.
- Cabe aclarar que los k pueden ser diferentes. EAC no asume el número de clusters k_i para cada partición obtenida P^i , por lo que cada k_i pueden ser no sólo diferentes al número de clusters buscado por EAC, sino que también entre sí.

- Sea $X = x_1, x_2, \dots, x_n$ nuestro conjunto de datos donde $x_i \in R^d$ y R^d es un espacio de d features.
- Partición P que encuentra k clusters
- Dado N algoritmos de clustering podemos entonces derivar N particiones P

- Sea $X = x_1, x_2, \dots, x_n$ nuestro conjunto de datos donde $x_i \in R^d$ y R^d es un espacio de d features.
- Partición P que encuentra k clusters
- Dado N algoritmos de clustering podemos entonces derivar N particiones P
- Definimos al conjunto de estas particiones como:

$$\mathbb{P} = \{P^1, P^2, \dots, P^N\} \quad (5)$$

$$P^1 = \{C_1^1, C_2^1, \dots, C_{k_1}^1\} \quad \dots \quad P^N = \{C_1^N, C_2^N, \dots, C_{k_N}^N\} \quad (6)$$

2024-11-20

Evidence Accumulation Clustering

Evidence Accumulation Clustering

- Sea $X = x_1, x_2, \dots, x_n$ nuestro conjunto de datos donde $x_i \in R^d$ y R^d es un espacio de d features.
- Partición P que encuentra k clusters
- Dado N algoritmos de clustering podemos entonces derivar N particiones P
- Definimos al conjunto de estas particiones como:

$$\mathbb{P} = \{P^1, P^2, \dots, P^N\} \quad (5)$$

$$P^1 = \{C_1^1, C_2^1, \dots, C_{k_1}^1\} \quad \dots \quad P^N = \{C_1^N, C_2^N, \dots, C_{k_N}^N\} \quad (6)$$

- donde C_j^i es el cluster j th en la partición P^i , la cual tiene k_i clusters.
- Además, dado n_j^i como la cardinalidad de C_j^i , se cumple que $\sum_{j=1}^{k_i} n_j^i = n$, $i = 1, \dots, N$.
- Cabe aclarar que los k pueden ser diferentes. EAC no asume el número de clusters k_i para cada partición obtenida P^i , por lo que cada k_i pueden ser no sólo diferentes al número de clusters buscado por EAC, sino que también entre sí.

Tres problemas a resolver, que definen cada etapa del algoritmo de EAC:

- 1 Cómo generamos el ensamble de particiones.
- 2 Cómo combinamos la evidencia.
- 3 Cómo extraemos una partición de datos (conjunto de clusters) consistente de la evidencia combinada.

2024-11-20

└ Evidence Accumulation Clustering

└ Evidence Accumulation Clustering


- Utilizaremos un algoritmo en particular, **k-means**, múltiples veces con **semillas diferentes** para generar el ensamble de clusters.

Evidence Accumulation Clustering

Tres problemas a resolver, que definen cada etapa del algoritmo de EAC:

- Cómo generamos el ensamble de particiones.
- Cómo combinamos la evidencia.
- Cómo extraemos una partición de datos (conjunto de clusters) consistente de la evidencia combinada.

Evidence Accumulation Clustering



Mecanismo de votación y métrica de similitud


$$C(i,j) = \frac{n_{ij}}{N}$$

Donde n_{ij} es el número de veces que el par de puntos (i,j) son asignados al mismo cluster en N particiones.

2024-11-20

Evidence Accumulation Clustering

Evidence Accumulation Clustering




- Una vez obtenido el ensamble de particiones, pasaremos a combinar la información proveída de estos con una **matriz de co-asociación**. Esta nos permitirá **relacionar la información obtenida** con cada partición incluso si la cardinalidad varía entre ellas.
- Bajo la suposición de que dos puntos **pertenecen al mismo cluster** si se encontraron **en el mismo cluster repetidas veces** en el ensamble de particiones
- Una vez generada la **matriz de similitud** podemos aplicar **cualquier algoritmo de clustering sobre ésta**. El paper original opta por utilizar **clustering jerárquico aglomerativo** con **single o average** linkage, por lo que seguimos con eso.

<https://pycombo.readthedocs.io/en/latest/>
<https://github.com/originalnicodr/combo>

- Porque forkeamos la libreria

Abadi: Detección de 2 componentes

- $N = 500$
- k-means con $k_i = 100, i = 1, \dots, N.$
- Clustering Jerárquico aglomerativo con single linkage




2024-11-20

Evidence Accumulation Clustering

Abadi: Detección de 2 componentes

- Hemos probado con $N = 500$, pero **tardaba aun mas (cuatro dias)**, por lo cual optamos por reducir el numero de particiones a buscar a 100
- La diferencia con $N=500$ era casi **imperceptible**
- Pero sigue siendo muy **caro computacionalmente**, por eso redujimos el analisis a tan solo **tres galaxias**, y dado los resultados feos que estamos viendo no valia la pena probarlos con todas (la falta de galaxias no es de gran impacto para nuestro analisis)
- **Por que da asi?** Antes de explicar:




AGMM: Detección de $\Rightarrow 2$ componentes

2024-11-20


└ Evidence Accumulation Clustering

└ AGMM: Detección de $\Rightarrow 2$ componentes

AGMM: Detección de $\Rightarrow 2$ componentes



AutoGMM



EAC

- $N = 100$ denuevo
- seguimos con alto costo computacional
- Entendiendo eso, creemos que usar **valores MUY altos de k** puede entrometerse con encontrar los **patrones buscados en el dataset**. Resultando de esta manera en una matriz de consenso ruidosa y que **no captura las co-ocurrencias de los puntos**.
- También descubrimos que uno de los experimentos que propone el paper original es **variar los valores de k** utilizados por cada k-means (dentro de las cotas adecuadas) en una misma corrida de EAC, siendo esto al parecer **más robusto** que utilizar un k fijo.
- **Ambas razones** pueden haber sido las causantes de la forma de los resultados obtenidos. Pero de igual manera con los tiempos de computos requeridos por el algoritmo, no habia tiempo para buscar estas cotas como hiperparametros.
- Con los experimentos realizados **no nos es posible recomendar eac** como alternativa para abadi ni para agmm.

└─ Conclusiones

└ Conclusiones

Resultados de Clustering Jerárquico son cercanos a los de Abadi (entendiendo las limitaciones de usar una sola feature). Pero el alto costo computacional y de memoria en comparación indican que no es una buena alternativa.

- 1 Resultados de Clustering Jerárquico son cercanos a los de Abadi (entendiendo las limitaciones de usar una sola feature). Pero el alto costo computacional y de memoria en comparacion indican que no es una buena alternativa.

1. Cabe aclarar que, cuando hablamos de estos algoritmos como posibles **alternativas** a las ya propuestas en el área, hablamos estrictamente respecto a la tarea de **encontrar clusters de forma similares**. Es decir, dado que los algoritmos usados en este trabajo son de uso general en minería de datos no es posible para ellos **etiquetar** cada cluster con la etiqueta correspondiente.
Responsabilidad que queda a cargo de quien corre dichos métodos.

- 1 Resultados de Clustering Jerárquico son cercanos a los de Abadi (entendiendo las limitaciones de usar una sola feature). Pero el alto costo computacional y de memoria en comparación indican que no es una buena alternativa.
- 2 Clustering Jerárquico obteniendo resultados similares a los de Abadi lo reconfirma, como así también con AGMM.

1. Cabe aclarar que, cuando hablamos de estos algoritmos como posibles **alternativas** a las ya propuestas en el área, hablamos estrictamente respecto a la tarea de **encontrar clusters de forma similares**. Es decir, dado que los algoritmos usados en este trabajo son de uso general en minería de datos no es posible para ellos **etiquetar** cada cluster con la etiqueta correspondiente. **Responsabilidad** que queda a cargo de quien corre dichos métodos.
2. La **tendencia** de HC a obtener resultados similares a los de Abadi es un **indicativo extra** del éxito de este último como algoritmo para identificar componentes.

- 1 Resultados de Clustering Jerárquico son cercanos a los de Abadi (entendiendo las limitaciones de usar una sola feature). Pero el alto costo computacional y de memoria en comparación indican que no es una buena alternativa.
- 2 Clustering Jerárquico obteniendo resultados similares a los de Abadi lo reconfirma, como así también con AGMM.
- 3 Dada que la naturaleza de ciertas subcomponentes alejados a los conceptos usuales de clusterización, los métodos presentados que no asignan una interpretación física a los valores no harán un buen trabajo sobre estas con las features trabajadas.

1. Cabe aclarar que, cuando hablamos de estos algoritmos como posibles **alternativas** a las ya propuestas en el área, hablamos estrictamente respecto a la tarea de **encontrar clusters de forma similares**. Es decir, dado que los algoritmos usados en este trabajo son de uso general en minería de datos no es posible para ellos **etiquetar** cada cluster con la etiqueta correspondiente. **Responsabilidad** que queda a cargo de quien corre dichos métodos.
2. La **tendencia** de HC a obtener resultados similares a los de Abadi es un **indicativo extra** del éxito de este último como algoritmo para identificar componentes.
3. El Bulge y el Halo

- 1 Resultados de Clustering Jerárquico son cercanos a los de Abadi (entendiendo las limitaciones de usar una sola feature). Pero el alto costo computacional y de memoria en comparación indican que no es una buena alternativa.
- 2 Clustering Jerárquico obteniendo resultados similares a los de Abadi lo reconfirma, como así también con AGMM.
- 3 Dada que la naturaleza de ciertas subcomponentes alejados a los conceptos usuales de clusterización, los métodos presentados que no asignan una interpretación física a los valores no harán un buen trabajo sobre estas con las features trabajadas.

1. Cabe aclarar que, cuando hablamos de estos algoritmos como posibles **alternativas** a las ya propuestas en el área, hablamos estrictamente respecto a la tarea de **encontrar clusters de forma similares**. Es decir, dado que los algoritmos usados en este trabajo son de uso general en minería de datos no es posible para ellos **etiquetar** cada cluster con la etiqueta correspondiente. **Responsabilidad** que queda a cargo de quien corre dichos métodos.
2. La **tendencia** de HC a obtener resultados similares a los de Abadi es un **indicativo extra** del éxito de este último como algoritmo para identificar componentes.
3. El Bulge y el Halo

└─Conclusiones

1. Desincentivando de esta manera cualquier aplicación de este método en la practica. Al menos con la **implementación utilizada**.

- 4 Fuzzy Clustering también presenta tendencias similares a Abadi, y entendiendo sus limitaciones podría considerarse como una buena alternativa. Pero su comportamiento dista de ser el buscado con mas de 2 clusters para ser considerado una alternativa a AGMM.
- 5 Los resultados obtenidos por Evidence Accumulation Clustering estan lejos de ser similares a los provenientes de Abadi y AGMM. Además, su costo computacional y de memoria son varios ordenes de magnitud mas grandes.

1. Desincentivando de esta manera cualquier aplicación de este método en la practica. Al menos con la **implementación utilizada**.

- 4 Fuzzy Clustering también presenta tendencias similares a Abadi, y entendiendo sus limitaciones podría considerarse como una buena alternativa. Pero su comportamiento dista de ser el buscado con mas de 2 clusters para ser considerado una alternativa a AGMM.
- 5 Los resultados obtenidos por Evidence Accumulation Clustering estan lejos de ser similares a los provenientes de Abadi y AGMM. Además, su costo computacional y de memoria son varios ordenes de magnitud mas grandes.
- 6 Las métricas internas utilizadas, Davies–Bouldin y Silhouette, no son de utilidad para analizar el desempeño de algoritmos de clustering en el problema presentado, dada la naturaleza de las componentes reales de una galaxia y como estas difieren de, lo que entienden estas métricas, son buenos clusters.

1. Desincentivando de esta manera cualquier aplicación de este método en la practica. Al menos con la **implementación utilizada**.
2. Además, **no fue posible concluir** con ninguno de los métodos explorados si el **remove outliers** beneficia o no la tarea de buscar los clusters deseados. Dificultando, además, el análisis al buscar un numero variables de clusters dada la variabilidad de la cardinalidad de estos ocasionada por remover partículas estelares de los datos.

- 4 Fuzzy Clustering también presenta tendencias similares a Abadi, y entendiendo sus limitaciones podría considerarse como una buena alternativa. Pero su comportamiento dista de ser el buscado con mas de 2 clusters para ser considerado una alternativa a AGMM.
- 5 Los resultados obtenidos por Evidence Accumulation Clustering estan lejos de ser similares a los provenientes de Abadi y AGMM. Además, su costo computacional y de memoria son varios ordenes de magnitud mas grandes.
- 6 Las métricas internas utilizadas, Davies–Bouldin y Silhouette, no son de utilidad para analizar el desempeño de algoritmos de clustering en el problema presentado, dada la naturaleza de las componentes reales de una galaxia y como estas difieren de, lo que entienden estas métricas, son buenos clusters.

1. Desincentivando de esta manera cualquier aplicación de este método en la practica. Al menos con la **implementación utilizada**.
2. Además, **no fue posible concluir** con ninguno de los métodos explorados si el **remove outliers** beneficia o no la tarea de buscar los clusters deseados. Dificultando, además, el análisis al buscar un numero variables de clusters dada la variabilidad de la cardinalidad de estos ocasionada por remover partículas estelares de los datos.

Trabajo a futuro

- 1 Extender el dataset propuesto para realizar experimentos con galaxias espirales.

2024-11-20

Conclusiones

└ Trabajo a futuro

Trabajo a futuro

- 1 Extender el dataset propuesto para realizar experimentos con galaxias espirales.
- 2 Normalización del espacio dinámico antes de correr los metodos vistos.
- 3 Explorar otro tipo de preprocesamientos sobre el espacio dinámico antes de aplicar los métodos propuestos.

2024-11-20

└ Conclusiones

└ Trabajo a futuro

1. (2) En especial HC y FCM

2024-11-20

└ Trabajo a futuro

- 1 Extender el dataset propuesto para realizar experimentos con galaxias espirales.
- 2 Normalización del espacio dinámico antes de correr los metodos vistos.
- 3 Explorar otro tipo de preprocesamientos sobre el espacio dinámico antes de aplicar los métodos propuestos.
- 4 Aplicar diferentes variaciones sobre el primer paso del algoritmo de Evidence Accumulation Clustering.

1. (2) En especial HC y FCM

2024-11-20

└ Trabajo a futuro

- 1 Extender el dataset propuesto para realizar experimentos con galaxias espirales.
- 2 Normalización del espacio dinámico antes de correr los metodos vistos.
- 3 Explorar otro tipo de preprocesamientos sobre el espacio dinámico antes de aplicar los métodos propuestos.
- 4 Aplicar diferentes variaciones sobre el primer paso del algoritmo de Evidence Accumulation Clustering.
- 5 Correr Evidence Accumulation Clustering variando los valores de k de cada k-means, buscando la cota inferior y superior de dicha variación como hyperparametros.

1. (2) En especial HC y FCM

└ Conclusiones

└ Trabajo a futuro

1. (2) En especial HC y FCM
2. (6) Sean del area de data mining o algunas mas complejas del area de la astronomia

- 1 Extender el dataset propuesto para realizar experimentos con galaxias espirales.
- 2 Normalización del espacio dinámico antes de correr los metodos vistos.
- 3 Explorar otro tipo de preprocesamientos sobre el espacio dinámico antes de aplicar los métodos propuestos.
- 4 Aplicar diferentes variaciones sobre el primer paso del algoritmo de Evidence Accumulation Clustering.
- 5 Correr Evidence Accumulation Clustering variando los valores de k de cada k-means, buscando la cota inferior y superior de dicha variación como hyperparametros.
- 6 Aplicar otras técnicas de eliminación de outliers.
- 7 Explorar otras features del dataset que podrían contener mas información útil.

2024-11-20

Conclusiones

Trabajo a futuro

1. (2) En especial HC y FCM
2. (6) Sean del area de data mining o algunas mas complejas del area de la astronomia
3. (7) Para encontrar componentes con los métodos propuestos, como la **edad** o la **metalicidad**.

- 1 Extender el dataset propuesto para realizar experimentos con galaxias espirales.
- 2 Normalización del espacio dinámico antes de correr los metodos vistos.
- 3 Explorar otro tipo de preprocesamientos sobre el espacio dinámico antes de aplicar los métodos propuestos.
- 4 Aplicar diferentes variaciones sobre el primer paso del algoritmo de Evidence Accumulation Clustering.
- 5 Correr Evidence Accumulation Clustering variando los valores de k de cada k-means, buscando la cota inferior y superior de dicha variación como hyperparametros.
- 6 Aplicar otras técnicas de eliminación de outliers.
- 7 Explorar otras features del dataset que podrían contener mas información útil.

- 1 Extender el dataset propuesto para realizar experimentos con galaxias espirales.
- 2 Normalización del espacio dinámico antes de correr los metodos vistos.
- 3 Explorar otro tipo de preprocesamientos sobre el espacio dinámico antes de aplicar los métodos propuestos.
- 4 Aplicar diferentes variaciones sobre el primer paso del algoritmo de Evidence Accumulation Clustering.
- 5 Correr Evidence Accumulation Clustering variando los valores de k de cada k-means, buscando la cota inferior y superior de dicha variación como hyperparametros.
- 6 Aplicar otras técnicas de eliminación de outliers.
- 7 Explorar otras features del dataset que podrían contener mas información útil.

2024-11-20

Conclusiones

Trabajo a futuro

1. (2) En especial HC y FCM
2. (6) Sean del area de data mining o algunas mas complejas del area de la astronomia
3. (7) Para encontrar componentes con los métodos propuestos, como la **edad** o la **metalicidad**.

- 1 Extender el dataset propuesto para realizar experimentos con galaxias espirales.
- 2 Normalización del espacio dinámico antes de correr los metodos vistos.
- 3 Explorar otro tipo de preprocesamientos sobre el espacio dinámico antes de aplicar los métodos propuestos.
- 4 Aplicar diferentes variaciones sobre el primer paso del algoritmo de Evidence Accumulation Clustering.
- 5 Correr Evidence Accumulation Clustering variando los valores de k de cada k-means, buscando la cota inferior y superior de dicha variación como hyperparametros.
- 6 Aplicar otras técnicas de eliminación de outliers.
- 7 Explorar otras features del dataset que podrían contener mas información útil.

Scripts: github.com/originalnicodr/GalaxyMLDecompositionThesis

 github.com/originalnicodr

 twitter.com/originalnicodr

 linkedin.com/in/nicolas-uriel-navall

 niconavall@gmail.com

 originalnicodr.github.io

2024-11-20

- └─ Conclusiones
- └─ Contacto

Contacto

Scripts: github.com/originalnicodr/GalaxyMLDecompositionThesis

 github.com/originalnicodr

 twitter.com/originalnicodr

 linkedin.com/in/nicolas-uriel-navall

 niconavall@gmail.com

 originalnicodr.github.io

Scripts: github.com/originalnicodr/GalaxyMLDecompositionThesis



 github.com/originalnicodr

 linkedin.com/in/nicolas-uriel-navall

 originalnicodr.github.io

 twitter.com/originalnicodr

 niconavall@gmail.com

2024-11-20

└─ Conclusiones

└─ Contacto

Contacto

Scripts: github.com/originalnicodr/GalaxyMLDecompositionThesis



 github.com/originalnicodr  twitter.com/originalnicodr
 linkedin.com/in/nicolas-uriel-navall  niconavall@gmail.com
 originalnicodr.github.io